



**Tecnológico
de Monterrey**

Avance Dataset sin Framework

Aplicación de métodos multivariados en ciencia de datos

Juan Sebastián Chitiva Guerrero

A01276239

Fecha de entrega:

30 de Agosto de 2026

Introducción al tema

La música es un rasgo importante en la vida de muchas personas alrededor del mundo. Es su manera de despejarse y de poder relajar la mente. Gracias a esto, existen una larga cantidad de aplicaciones y maneras para poder escuchar música. En este reporte, se busca analizar y poder clasificar cuales han sido los momentos en los que las personas han decidido cancelar su suscripción de una aplicación llamada “Playlist Pro”. Se hace el análisis ya que la empresa busca encontrar alguna relación entre la decisión de los usuarios de cancelar la suscripción y poder implementar medidas para que se minimicen estos casos.

1. Comprensión de los datos

1.1 Información Inicial

Se ha dado un dataset que contiene 41,000 muestras y 20 columnas. En estos se tiene información característica sobre el usuario y sobre su uso en la aplicación, métodos de pago, tipo de pago, entre otros.

1.2 Objetivos analíticos

Se busca construir una clasificación entre las personas que siguen activas contra los clientes que han decidido cancelar su suscripción. Este se hará de forma binaria, definiendo el valor “1” para determinar los que han decidido cancelar este mismo. También se busca encontrar patrones para poder diferenciar ambas categorías de usuarios.

1.3 Definiciones y métricas clave

- **Churned:** Persona que ha cancelado su suscripción (0=activo, 1=cancelado)

Métricas principales: Se realizará un modelo que tenga dos clases, una clase que contenga los usuarios activos y los que han cancelado. Este algoritmo se medirá con las siguientes métricas:

- **Accuracy**

- **Recall de la clase positiva (usuarios cancelados)**

Análisis inicial de dataset:

Para poder hacer esto, se provee una base de datos la cual contiene 41,000 muestras de usuarios de Estados Unidos, las cuales contienen los siguientes atributos:

Diccionario de Variables

Variable	Descripción	Tipo
Customer ID	Identificador de cada cliente	Numérica
Age	Edad del cliente	Numérica
Location	Estado de residencia del cliente.	Categórica
Subscription Type	Tipo de suscripción	Categórica
Payment Plan	Forma en la que el cliente hace el pago de suscripción, siendo este anual o mensual	Categórica
Num Subscription Pauses	Número de veces que el usuario ha pausado su suscripción (Máximo 2 veces)	Categórica
Payment Method	Forma de pago del usuario	Categórica
Customer Service Inquiries	Frecuencia que el usuario ha necesitado un servicio a cliente	Categórica

Sign up Date	Fecha en la que el usuario comenzó su suscripción	Fecha
Weekly Hours	Promedio mensual que el usuario escucha música	Numérica
Average Session Length	Promedio por sesión que el usuario escucha música	Numérica
Song Skip Rate	Porcentaje de canciones que el usuario no termina de escuchar y salta	Numérica
Weekly Songs Played	Promedio de canciones que el usuario escucha por semana	Numérica
Weekly Unique Songs	Promedio de canciones únicas que el usuario escucha en una semana.	Numérica
Num Favorite Artists	Número de artistas que el usuario definió como artista favorito.	Numérica
Num Platform Friends	Número de conecciones con otros usuarios que se tiene dentro de la app.	Numérica
Num Playlists Created	Número de playlists creadas por el usuario	Numérica
Num Shared Playlists	Número de playlists que ha compartido públicamente	Numérica

Notificaciones Clicked	Número de notificaciones dentro de la app que el usuario ha clickeado.	Numérica
Churned	Identificador si el usuario es activo o si se dio de baja	Categórica de clase (Variable a Predecir)

2. Auditoría de datos

2.1 Revisión de completitud y valores faltantes

- Identificación de variables con valores nulos o vacíos.

Analizando las columnas que se usaron en el diccionario de variables, se puede observar que no existían valores vacíos ni valores duplicados, lo cual no fue necesario hacer limpieza en ese aspecto.

- Identificación de errores en variables categóricas

Analizando las columnas categóricas, se hizo un análisis de valores para observar si podían existir errores ortográficos o gramaticales que afectaran los resultados. Se encontró un error en la variable “location” en la cual se describía un estado como “Nebrasksa” y se sustituyó a “Nebraska”. De ahí en fuera no se encontró ningún otro error.

2.2 Codificación de variables categóricas

En los casos de las variables categóricas, se tienen las siguientes columnas: Location, Subscription Type, Payment Plan, Num Subscription Pauses, Payment Method, Customer Service Inquiries.

Para poder analizarlo en el modelo, se transformaron todas las categorías en valores numéricos mediante One-Hot Encoding. De esta manera, se pueden incluir como variables predictoras en los modelos.

2.3 Eliminación de columnas

Al observar la información de todas las columnas, no se ha determinado ninguna como candidata a ser eliminada. Aunque se ha redefinido el index por la columna “**customer_id**” por limpieza y estructura de la base de datos.

2.4 Estandarización de Variables Numéricas

OkeyDebido a la diferencia tanto en unidades como en escala de las variables numéricas, se busca estandarizar las variables numéricas. Para esto, se utiliza el método de Standard Scaler, el cual tiene como propósito permite poder interpretar resultados basado en su desviación y su media. Hacer esto logra poder tener variables en una escala de tal manera que sean comparables entre ellos.

3. Análisis Exploratorio

3.1 Correlaciones

Observando la matriz de correlación entre las variables numéricas, la cual se encuentra en el Anexo como “**AI**”, se observa una relación bastante alta entre las variables “weekly_hours”, “weekly_songs_played”, “weekly_unique_songs” y “num_favorite_artists”. Esto tiene sentido ya que, al tener una mayor cantidad de horas de música escuchadas, aumenta la cantidad de canciones que se escuchan. La relación entre el número de artistas favoritos con el numero de horas se podría interpretar como el grupo de usuarios que utilizan frecuentemente la aplicación y tienen un nivel de actividad alto. Observando esto y con el propósito de reducir información redundante, se reducen estas variables directamente en el número de horas semanal y solo se mantendrá este atributo.

3.1 Datos relevantes

La base de datos, respecto a la variable predictora “churned” contiene 32,253 usuarios que siguen activos y 8,747 que han cancelado su suscripción (Esto representa el 76.8% y 21.3% del dataset, respectivamente).

4. Selección y preparación de Modelo

4.1 Selección de Modelo

En el dataset, se implementa este método de aprendizaje supervisado que es utilizado para realizar problemas de clasificación binaria. Con este, se busca encontrar una relación entre las variables independientes y la variable, la cual en este caso sería “churned”. Observando el contexto del problema, se considero adecuado una regresión logística, ya que permite estimar la probabilidad de que clase pertenece el usuario, esto en base a sus características y usos de la aplicación. De esta forma, se puede realizar predicciones e identificar posibles usuarios que busquen cancelar su suscripción e implementar nuevas estrategias que disminuyan el porcentaje de cancelación.

Este modelo se realiza con una **función sigmoideal**, la cual tiene como propósito transformar el resultado de la combinación lineal de las variables independientes en un valor que tiene un intervalo de 0 y 1. Así, se puede interpretar como una probabilidad de pertenencia hacia la clase 1, la cual en nuestro caso es el usuario que cancela su suscripción.

La función tiene como entrada la combinación lineal de variables dependientes y los pesos de cada uno. Cada muestra tiene su propia combinación, la cual se define como:

$$z = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$$

Se define la función sigmoideal como:

$$\hat{y} = \frac{1}{1+e^{-z}}$$

Este resultado representa la probabilidad de cada usuario a pertenecer a la clase 1.

4.2 Selección de Datos

Una vez que se realizó el análisis exploratorio y se ha escogido el modelo a utilizar, se busca seleccionar las variables independientes que serán utilizados en este mismo. Se define la columna “churned” como la variable dependiente y las columnas ya mencionadas anteriormente como las dependientes (Cabe mencionar que las columnas categóricas ya han sido transformadas a través de one hot encoding).

4.2 Split de Dataset

Posteriormente, se divide la información en dos conjuntos de datos, una parte enfocada en el entrenamiento del modelo, llamada **train**, y una parte enfocada en probar la eficacia del modelo ya entrenado, llamada **test**. La división se realizó con un 80% enfocada a la parte de entrenamiento y un 20% hacia la parte de prueba.


Cabe recordar que, antes de seguir con el proceso de entrenamiento, las variables categóricas y numéricas ya han sido transformadas para ser implementadas en el modelo y sea comparable uno ente otro. Además, se ha incorporado un *bias* para cada observación, de tal manera que pueda formar parte de la combinación lineal utilizada en la función de hipótesis.

5. Entrenamiento de Modelo

El modelo comienza inicializando los pesos respecto a las variables independientes. Para cada observación calcula una combinación lineal entre las características y los pesos. Una vez realizado eso, se alimenta a la función sigmoideal para obtener la probabilidad de pertenecer a la clase 1.

Una vez que se obtiene la predicción, se compara los resultados de la predicción respecto al valor real de la variable objetivo. La diferencia entre estos dos determinan el error de la predicción.

En base a esto, se ajustan los pesos con el método de gradiente descendiente, buscando encontrar los pesos óptimos que minimicen el error del modelo lo más posible. En cada iteración busca calcular el gradiente para la observaciones y se actualizan con una tasa de aprendizaje ya definida.



fórmula de gradiente descendiente

Una vez implementada esta fórmula, los pesos se irán actualizando de forma sucesiva en la dirección que minimice la función de costo.

Después de la actualización de los pesos, se calculan las nuevas probabilidades de cada muestra con estos nuevos pesos y de esta forma se determina el costo del modelo utilizando la función de entropía cruzada (cross-entropy).

Esta función de costo nos permite medir la distancia entre las probabilidades estimadas por el modelo respecto a las clases reales. El menor valor de costo representa un mejor ajuste entre la predicción del modelo y las clases reales.


Tras terminar la primera iteración, se almacena el valor de costo de la entropía cruzada, esto con el propósito de observar el comportamiento del modelo y como mientras va avanzando mejora las predicciones.

En el modelo se establece un máximo de 100 iteraciones. El límite permite que el algoritmo continúe ajustando los pesos durante un número limitado de iteraciones, aunque se puede terminar antes si alcanza una condición de convergencia definida. Se acostumbra tener una mayor cantidad, pero al ser un modelo “rústico” y sin optimizar, toma más tiempo del esperado.

6. Resultados

Para analizar los resultados, se ha incluido la gráfica de costo a través de cada iteración. En este, se puede observar que el modelo si comienza a bajar de costo.

En este gráfico se puede observar que mientras pasa el tiempo, disminuye el costo del modelo. Por lo tanto, si está funcionando de forma adecuada el modelo. Cabe aclarar que son pocas las iteraciones que se realizan para el modelo y se podría mejorar para que permita una mayor cantidad de iteraciones y así logre tener un resultado mejor.



Para las métricas, se han utilizado Accuracy, recall y la matriz de confusión. Accuracy nos permite saber que tantas predicciones fueron correctas respecto a toda la base de predicción. Es decir, de todo el set de prueba, cuantos logró predecir de forma adecuada el modelo. Recall sobre la clase 1 permite saber cuantos usuarios que realmente cancelaron se lograron detectar en base a las predicciones del modelo. Ambas métricas se obtienen a través de la matriz de confusión, la cual nos permite analizar la predicción de cada una de las clases. Esto lo hace a través de falsos y positivos. Captura cuales si fueron predecidos de forma adecuada y cuales fueron falsos positivos y falsos negativos.

Observando los resultados de entrenar el set de prueba, observamos que el modelo predice

que todos son negativos. Esto se debe a que son pocas las iteraciones y no permite capturar de forma adecuada los resultados. También se calcula el mínimo y máximo de las probabilidades obtenidas a través del modelo.

Cabe mencionar que el umbral de decisión está

```
Probabilidad mínima: 0.12230564292577847
Probabilidad máxima: 0.398376254620274
Probabilidad promedio: 0.24161546616800167
True Positive: 0
True Negative: 9685
False Positive: 0
False Negative: 2615
Recall clase 1: 0.0
Accuracy clase 1: 0.7874
```

en 0.5, lo cual se interpreta como: “Si mi probabilidad de que sea churn es mayor a 0.5, se le asigna la clase 1”. observando el máximo de probabilidad es del 39%, lo cual da a entender que para el modelo ningún usuario tiene suficiente probabilidad de superar ese 50% y clasificarlo como un posible usuario que cancelará suscripción.

6.1 Interpretación de modelo inicial

El modelo inicial es una regresión logística simple creada sin ningún framework, lo cual limite las iteraciones, efectividad y capacidad de encontrar relaciones suficientemente fuerte entre las variables para poder clasificar entre ambos usuarios. Los resultados sugieren que el modelo no logra captar esta relación y se buscaría posteriormente implementar un modelo más robusto que tenga una mayor fuerza y capacidad para poder encontrarlos.

Anexo

Anexo A1: Matriz de correlación

